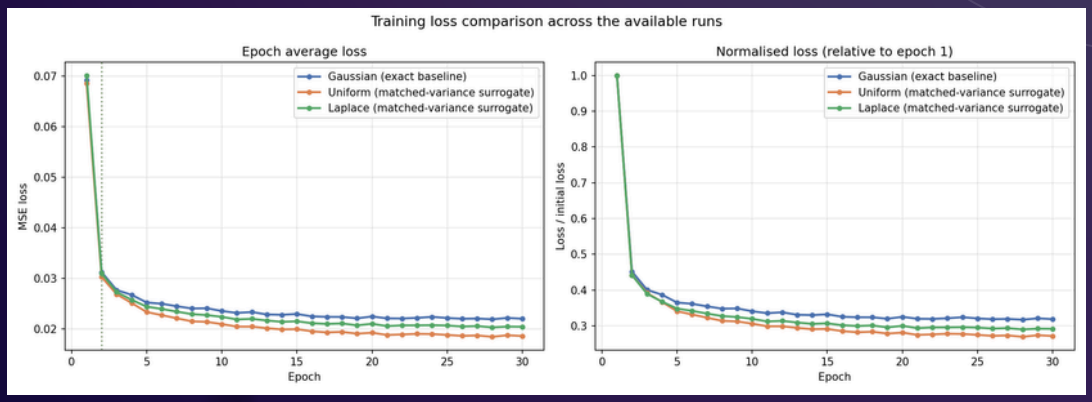
Résultat quantitatif global

Bruit	Loss finale	MSE moyenne	Temps
Gaussian	0.022	0.0226	23.1 min
Uniform	0.0186	0.0195	22.5 min
Laplace	0.0205	0.0209	22.5 min

Sur les métriques de débruitage, Uniform obtient la loss finale la plus basse et la MSE moyenne la plus faible. Laplace arrive ensuite, puis Gaussian.

Mais il faut être précis : ces valeurs mesurent surtout la capacité du modèle à prédire le bruit ajouté. Elles ne mesurent pas directement la qualité finale des images générées.

Courbes d'entraînement

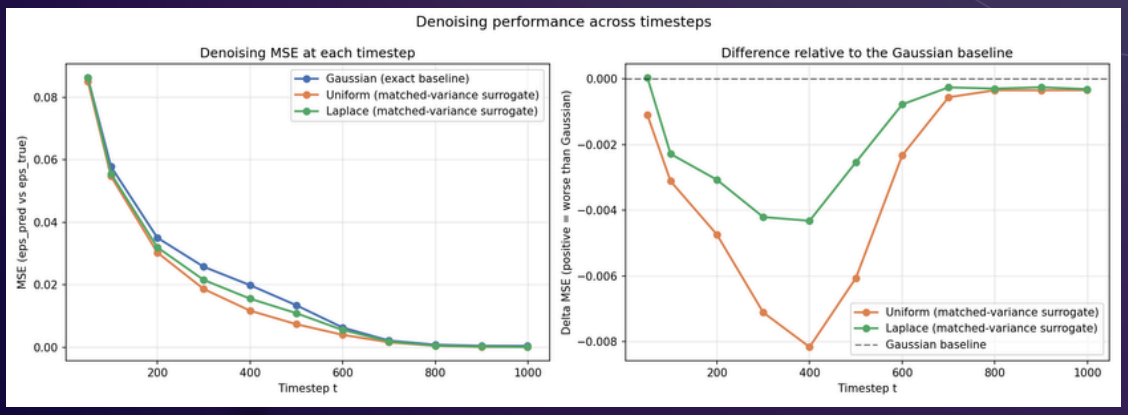


La courbe confirme le tableau. Uniform converge plus bas, Laplace reste proche, et Gaussian garde une loss plus élevée dans cette expérience.

Ce résultat montre que la forme statistique du bruit change vraiment la dynamique d'apprentissage. Même si la variance est comparable, le modèle ne voit pas exactement le même problème de débruitage.

Je ne conclus pas ici que Uniform est "meilleur" en général. Je dis simplement qu'il est meilleur sur cette métrique, dans ce protocole.

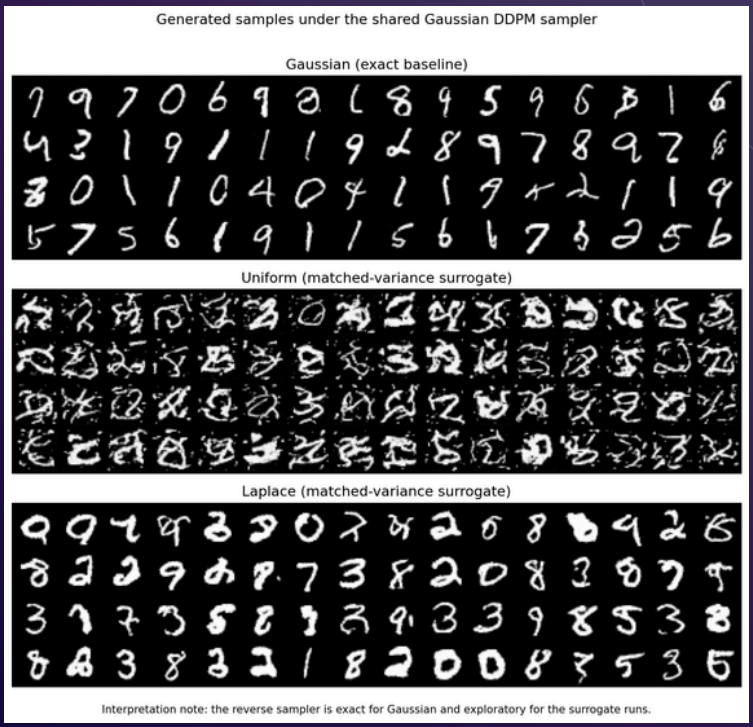
MSE selon le pas de diffusion



Cette figure montre que l'écart entre les trois bruits n'est pas uniforme sur toute la chaîne. Certains pas sont plus sensibles que d'autres.

Les pas intermédiaires sont particulièrement importants : l'image n'est ni presque propre, ni complètement bruitée. Le modèle doit encore exploiter de la structure, tout en corrigeant une corruption importante.

Uniform reste très bon sur cette métrique. Mais encore une fois, cela reste une mesure du débruitage, pas directement une mesure de qualité générative.

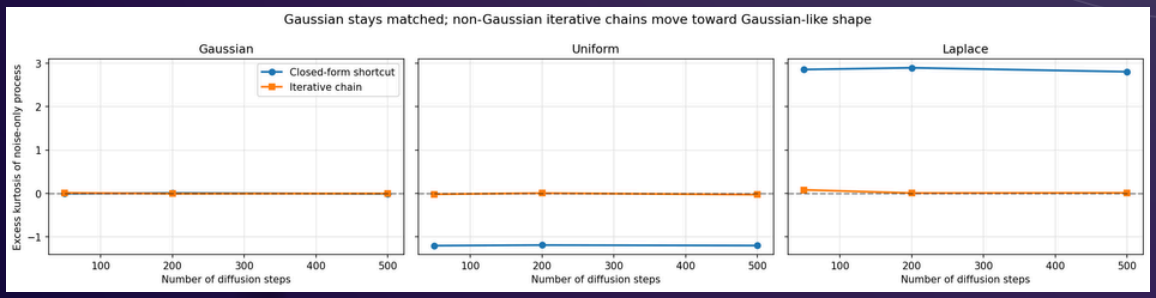


La comparaison visuelle change la lecture. Uniform avait les meilleurs scores numériques, mais ses images ne sont pas les plus stables visuellement. Gaussian reste plus régulier dans les samples, et Laplace donne un résultat intermédiaire.

L'explication principale est que le reverse sampler reste un sampler DDPM gaussien. Le cas Gaussian est donc le plus aligné avec le cadre théorique et le sampling utilisé.

Le résultat important est le décalage entre métriques de débruitage et qualité de génération. C'est ce point qui donne de la valeur à la partie résultats.

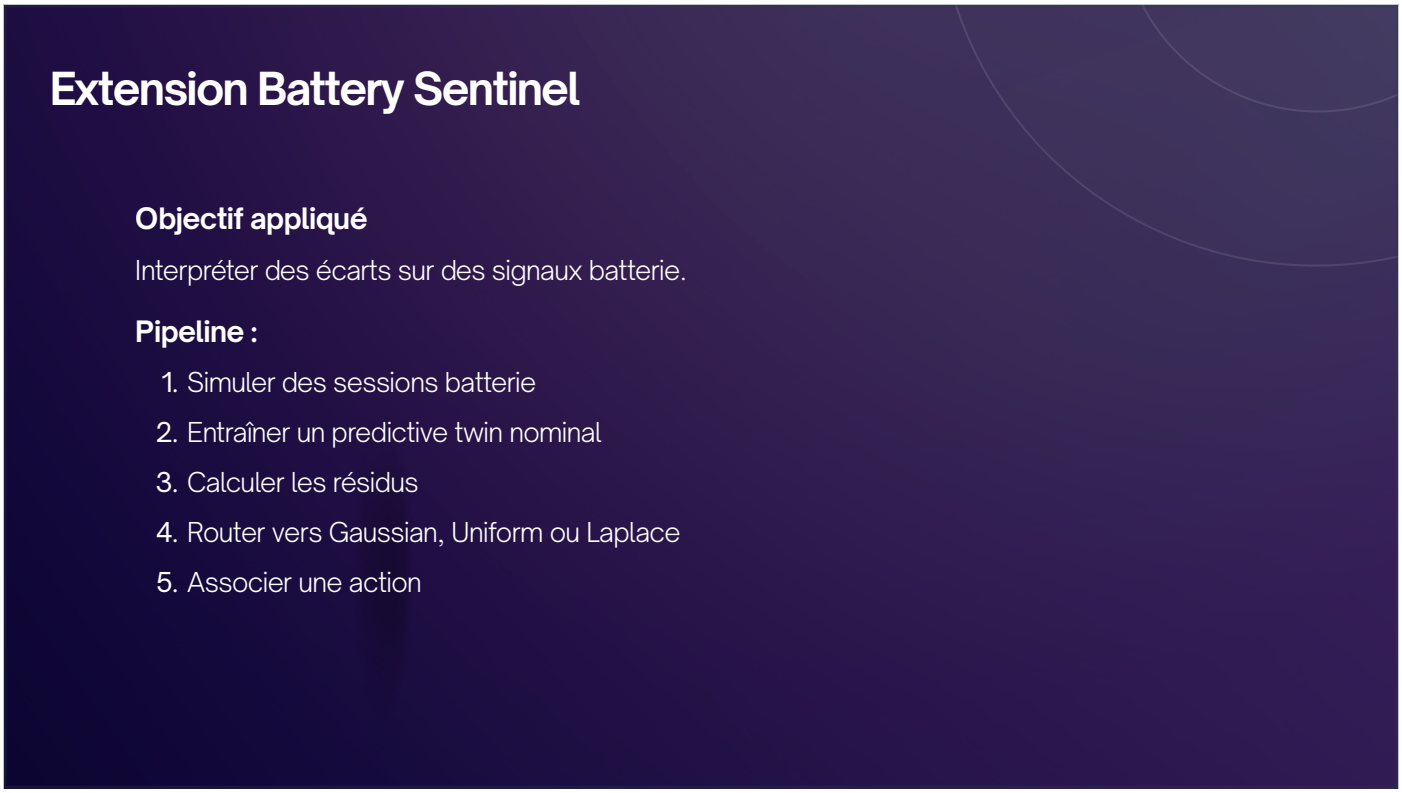
Lecture en trois régimes d'incertitude



La conclusion utile n'est pas seulement "tel bruit gagne". La conclusion utile est que les trois lois portent trois formes différentes d'incertitude.

Gaussian reste la référence DDPM. Uniform peut représenter une incertitude bornée, comme une mesure limitée en résolution. Laplace peut représenter des écarts plus brusques, parce que sa distribution donne plus de poids aux valeurs extrêmes.

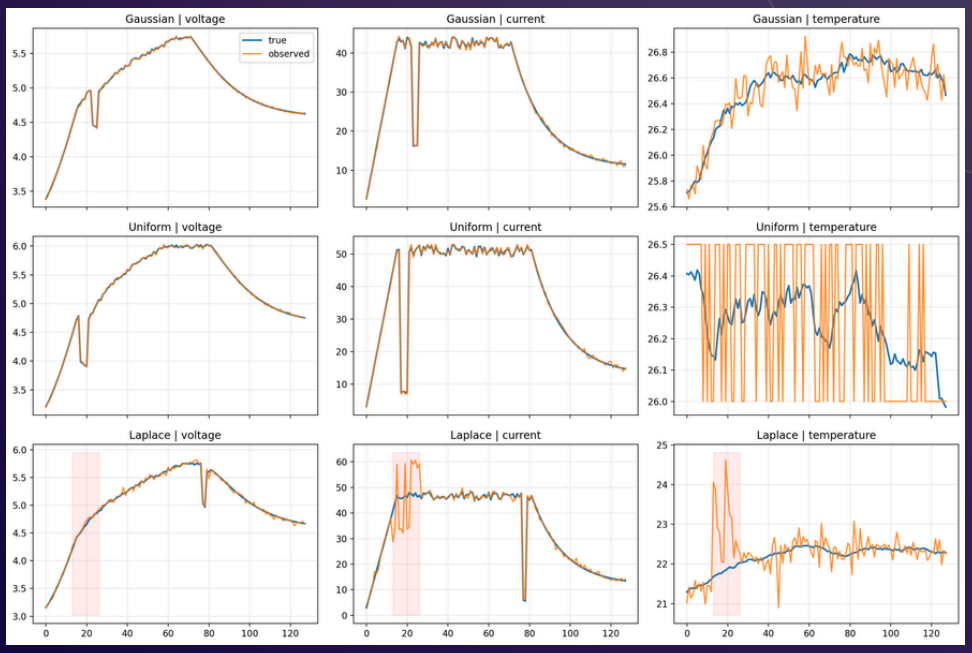
C'est cette lecture que je transpose ensuite vers un signal batterie.



Dans l'extension, on ne cherche plus à produire des images. On simule des signaux batterie avec quatre variables : SOC, voltage, current et temperature.

Le modèle apprend d'abord le comportement nominal. Ensuite, on observe l'écart entre la prédiction attendue et le signal réel. Cet écart devient la base de décision.

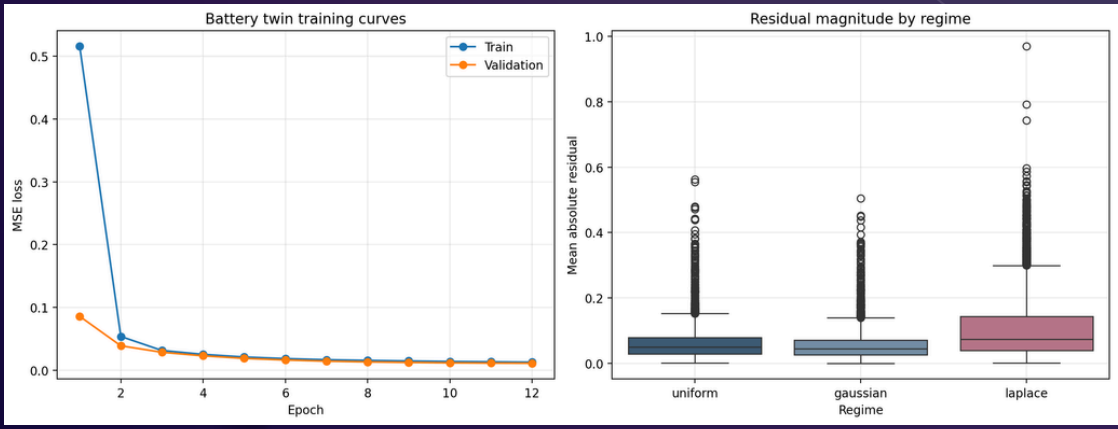
Le but n'est pas seulement de dire anomalie ou pas anomalie. Le but est de qualifier le type d'écart.



Le dataset est équilibré : 480 sessions par régime. Le régime Gaussian correspond au comportement nominal, Uniform introduit des effets bornés ou quantifiés, et Laplace introduit des ruptures plus brusques.

Le choix d'un dataset simulé est volontaire. Il permet de contrôler les causes et de vérifier si la logique tri-régime fonctionne dans un cadre propre.

Predictive twin nominal

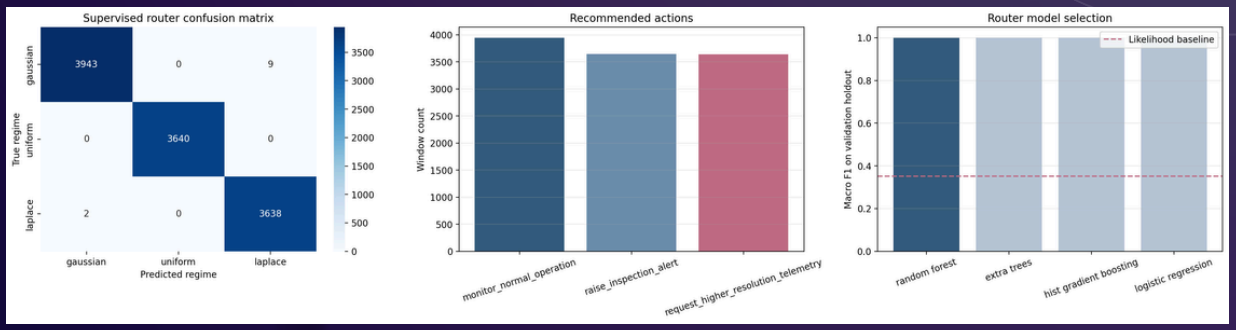


Le predictive twin est entraîné sur les fenêtres nominales. Il apprend donc ce qu'une trajectoire normale devrait produire.

Ensuite, on l'évalue sur les trois régimes. L'erreur est faible sur Gaussian, un peu plus élevée sur Uniform, et beaucoup plus forte sur Laplace.

C'est exactement ce qu'on attend : plus le signal s'éloigne du nominal, plus le résidu devient informatif.

Routeur tri-bruit



Le routeur utilise des features construites à partir des résidus et des signatures du signal. Le modèle retenu est un Random Forest.

Le score est très élevé : Macro-F1 et accuracy sont autour de 0.999. La matrice de confusion montre que les trois régimes sont presque toujours bien séparés.

Il faut cependant présenter ce résultat proprement : le dataset est simulé et structuré. Le score montre que la logique fonctionne dans ce cadre contrôlé, pas que le système est déjà validé industriellement.

De la prédiction à l'action

Régime prédit	Interprétation	Action
Gaussian	comportement normal	surveiller
Uniform	mesure bornée ou quantifiée	demander meilleure télémétrie
Laplace	rupture impulsive	inspection

La sortie finale est simple. Si le régime est Gaussian, le comportement reste compatible avec le nominal. Si le régime est Uniform, le système suggère plutôt un problème de résolution ou de télémétrie. Si le régime est Laplace, le système indique une rupture plus critique.

C'est là que la partie appliquée devient utile : on transforme un résidu numérique en interprétation exploitable

De la prédiction à l'action

Régime prédit	Interprétation	Action
Gaussian	comportement normal	surveiller
Uniform	mesure bornée ou quantifiée	demander meilleure télémétrie
Laplace	rupture impulsive	inspection

Le routeur utilise des features construites à partir des résidus et des signatures du signal. Le modèle retenu est un Random Forest.

Le score est très élevé : Macro-F1 et accuracy sont autour de 0.999. La matrice de confusion montre que les trois régimes sont presque toujours bien séparés.

Il faut cependant présenter ce résultat proprement : le dataset est simulé et structuré. Le score montre que la logique fonctionne dans ce cadre contrôlé, pas que le système est déjà validé industriellement.